

Estrutura De Compensação De Atraso Baseado No EKF Para Sistemas Não-Lineares Multivariáveis*

1st Leonardo José Fiori
Dept. Automação e Sistemas
Universidade Federal de Santa Catarina
Florianópolis, Brasil
leonardo.jf@posgrad.ufsc.br

2nd Daniel Martins Lima
Dept. Controle, Automação e Computação
Universidade Federal de Santa Catarina
Blumenau, Brasil
daniel.lima@ufsc.br

3rd Bruno Martins Lima
Dept. Automação e Sistemas
Universidade Federal de Santa Catarina
Florianópolis, Brasil
bruno.m.l@posgrad.ufsc.br

4th Julio Elias Normey-Rico
Dept. Automação e Sistemas
Universidade Federal de Santa Catarina
Florianópolis, Brasil
julio.normey@ufsc.br

Resumo—Este trabalho apresenta o uso do Filtro de Kalman Estendido (EKF) para compensação de atraso de transporte em processos não-lineares. O atraso é um desafio para o controle de processos, e o estudo propõe um preditor baseado na estrutura Observador-Preditor, utilizando o EKF como estimador. Esse preditor utiliza o EKF para estimar os estados do sistema e, em conjunto com o modelo do processo, realiza a predição dos estados ou saídas após o atraso. O preditor possui vantagens, como a estimação de diferentes tipos de perturbação e a aplicação em sistemas com diversas dinâmicas (estável ou não). Além disso, sua sintonia permite ajustar de forma simples as características de rejeição de perturbações e a robustez do sistema em malha fechada. O estudo de caso apresenta as vantagens da abordagem no contexto de um reator continuamente agitado. Um estudo de caso baseado num reator continuamente agitado é utilizado para apresentar as vantagens da proposta.

Index Terms—Filtro de Kalman Estendido, Preditor Não-Linear, Observador-Preditor, Sistemas com Atraso

I. INTRODUÇÃO

Os efeitos do atraso em sistemas de malha fechada são estudados há muito tempo e ainda atraem a atenção de pesquisadores. A presença do atraso tanto na representação contínua quanto discreta do modelo, faz com que este seja mais difícil de ser controlado com técnicas tradicionais quando se deseja alto desempenho [1].

O atraso é uma característica importante que explica fenômenos encontrados em processos químicos, sistemas de comunicação, sistemas de temperatura, e também pode ser utilizado para aproximar sistemas de alta ordem por sistemas de baixa ordem. Alguns dos problemas causados pelo atraso são: (a) quando há mudança na entrada do processo, o seu efeito só será sentido depois do atraso; (b) o efeito de perturbações não são sentidas imediatamente; (c) devido a (a) e (b), o controlador atua tentando corrigir algo que aconteceu no passado [2].

Para tratar os efeitos do atraso, tem-se a estrutura conhecida como Preditor de Smith ou SP (do inglês, *Smith Predictor*). Ela calcula uma predição da saída do processo

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Financiamento 001

utilizando informações da entrada e da saída do sistema, de forma que o controlador primário atua como se o sistema não tivesse atraso [1]. Assim, ao utilizar um preditor como o SP na malha de controle, o atraso não aparece na equação característica nominal de malha fechada, simplificando o projeto do controlador primário e do preditor que podem ser feitos de maneira independente [2], [3]. Entretanto, apesar do SP resolver diversos problemas relacionados a sistemas com atraso, não é possível aplicá-lo a sistemas integradores ou instáveis em malha aberta, motivando alterações na estrutura de maneira a obter soluções para esses casos como o preditor de Smith filtrado ou FSP (do inglês, *Filtered Smith Predictor*) [4] e o Preditor Generalizado Simplificado (SGP, do inglês *Simplified Generalized Predictor*) [5].

Independente do preditor, todos podem ser analisados como uma estrutura Observador-Preditor (O&P), apresentada na Fig. 1 [6]. Nessa estrutura, um observador é utilizado para estimar os estados da planta e o efeito de perturbações, e um preditor realiza a estimativa da saída d -passos adiante, sendo d o atraso discreto em número de amostras. Tomando




Figura 1. Estrutura observador-preditor. Fonte: [6] (adaptado).

como base a Fig. 1 e utilizando, por exemplo, o filtro de Kalman linear como observador, a estrutura pode ser chamada de Preditor de Kalman ou KP (do inglês *Kalman Predictor*). Com isso, foi mostrado em [7], que a estrutura apresenta certas características: (a) estimar diferentes tipos de perturbação; (b) pode ser implementado em sistemas de qualquer ordem e/ou dinâmica, como fase não-mínima, sistemas instáveis ou integradores; (c) pode-se trabalhar tanto em espaço de estados quanto em funções de transferência; (d) no caso SISO, possui apenas um parâmetro de projeto que pode ser ajustado para melhorar a rejeição de perturbação ou

robustez; (e) a implementação é feita diretamente no tempo discreto.

No entanto, grande parte das estruturas desse tipo são lineares e dependem de linearização do sistema não-linear próximos de um ponto de operação. Apesar de ser possível obter bons resultados em vários casos não-lineares práticos, o desempenho pode variar consideravelmente se o processo mudar de ponto de operação [8]. De acordo com [1], não há objeções para o uso de estruturas DTCs (do inglês, *Dead-Time Compensator*) em sistemas não-lineares. Ademais, para casos em que não há erros de modelagem, as vantagens do SP são mantidas. Entretanto, existem preditores não-lineares que têm compatibilidade direta com sistemas não-lineares e melhoram a resposta em malha fechada mas, em contrapartida, possuem dificuldades no estudo da estabilidade e robustez. Nesse sentido, pode-se utilizar do conceito O&P fazendo uso de um observador não-linear, como o filtro de Kalman estendido (EKF, do inglês, *Extended Kalman Filter*) ou o filtro de Kalman *unscented* (UKF, do inglês, *Unscented Kalman Filter*), permitindo explorar a estrutura de preditores não-lineares.

Há diversos trabalhos que abordam o uso de preditores não-lineares como [9] no qual é apresentado um controlador que estabiliza o processo com atraso que pode ser variável. Entretanto, não possui a predição de perturbações constantes, o que pode comprometer o seguimento de referência do sistema em malha fechada. Também em [10] é utilizado o EKF como estimador mas, da mesma forma, sem a predição das perturbações. Há também uma abordagem do EKF iterativo como MPC, apresentado em [13], no qual são realizadas análises teóricas sobre este conceito e também simulações em processos químicos e bioquímicos não-lineares monovariáveis, em que o IEKF-MPC, como foi chamado, apresenta resultados superiores em termos de rejeição de perturbação e resposta mais rápida do que o MPC padrão, além de um menor custo computacional. Em [27] é realizado um estudo sobre sintonia do KF na estrutura O&P, apresentando os efeitos da sintonia do preditor aplicado a dois exemplos em malha fechada. Ainda utilizando a estrutura O&P, [14] apresenta a comparação de uma técnica de controle conhecida como GLC (do inglês *Globally Linearizing Control*), usando um controlador PI, em conjunto com a predição do EKF com um estimador de ordem reduzida em malha aberta. A comparação é feita em um sistema não-linear em que a composição GLC-EKF apresentou melhores resultados que a técnica com estimação em malha aberta, devido à eficiência da convergência do EKF. Além disso, em [15] tem-se a aplicação num sistema de previsão da chegada de transporte público, no qual em uma comparação entre EKF e PF (do inglês, *Particle Filter*), é apresentado que o EKF é mais eficiente. Ademais, em [16] a estrutura O&P é aplicada para trabalhar com atrasos de comunicação entre sistemas, em que são aplicados estimadores EKF com alto ganho nos subsistemas para a previsão e compensação desse atraso. Com base no exposto, é possível ter uma breve noção do potencial que esta técnica tem, justificando seu estudo.

Assim, o presente trabalho tem por objetivo a adaptação do filtro de Kalman na estrutura O&P para sistemas não-lineares com atraso e do tipo MIMO (do inglês, *Multiple Input Multiple Output*). Para isso, serão estudadas técnicas não-

lineares do filtro de Kalman, as adaptações para a predição em sistemas com atraso e, através de simulação, avaliar o impacto da sintonia do preditor na estabilidade do sistema, bem como a influência na robustez e rejeição de perturbação.

O documento segue a seguinte organização: a revisão da literatura apresentando o filtro de Kalman, é apresentada na Seção II e o uso da estrutura O&P na Seção III. Na seção seguinte, estão descritos os resultados da aplicação da estrutura O&P com estimador não-linear. Finalmente, na Seção V, as conclusões e perspectivas futuras são apresentadas.

II. ESTIMADORES

Comumente, os estados são assumidos como medidos e determinísticos, o que nem sempre é a realidade, demandando algum algoritmo para estimação [17]. Juntamente com a estimação dos estados, os estimadores podem ser utilizados para atenuar o efeito de ruídos nas medições e identificar perturbações no sistema para garantir erro nulo na estimação dos estados. Para tratar esse problema, têm-se diversos estimadores de estados como os estimadores de Luenberger, modos deslizantes, alto ganho, filtro de Kalman, os quais podem ser lineares ou não-lineares, entre outros. Dentre estes, o filtro de Kalman será explanado nessa pesquisa por se tratar de um algoritmo de estimação em que não é necessário projetar o posicionamento dos polos e zeros do observador, o que o torna mais intuitivo, além da garantia de estabilidade para sistemas detectáveis [18]. Nesse sentido, serão abordados alguns desses estimadores no formato linear na Seção II-A e não-linear na Seção II-B.

A. Filtro de Kalman

O filtro de Kalman ou KF (do inglês, *Kalman Filter*), é um estimador linear quadrático que minimiza a variância do erro de estimação para um sistema linear descrito por

$$\begin{cases} x(k+1) = Ax(k) + Bu(k) + G\omega(k) \\ y(k) = Cx(k) + \nu(k) \end{cases}, \quad (1)$$

em que x é o vetor de estados, u o vetor de entradas e y o vetor de saídas, de dimensões n , m e p , respectivamente. A matriz $A \in \mathbb{R}^{n \times n}$ é a associada aos estados do sistema, $B \in \mathbb{R}^{n \times m}$ às entradas, $C \in \mathbb{R}^{p \times n}$ é a matriz que determina as saídas, $G \in \mathbb{R}^{n \times n}$ indica como os ruídos afetam os estados e $\omega(k) \in \mathbb{R}^n$ e $\nu(k) \in \mathbb{R}^p$ são ruídos gaussianos.

Os ruídos gaussianos considerados no sistema linear, são representados por vetores de média nula e a matriz de variância Q para ω e R para ν ou, utilizando notação matemática, como $\omega \sim \mathcal{N}(0, Q)$ e $\nu \sim \mathcal{N}(0, R)$, sendo $\mathcal{N}$ uma distribuição normal. Geralmente, as matrizes Q e R são definidas, de forma simplificada, como

$$Q = \begin{bmatrix} \delta_1^2 & 0 & \dots & 0 \\ 0 & \delta_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \delta_n^2 \end{bmatrix}, R = \begin{bmatrix} \lambda_1^2 & 0 & \dots & 0 \\ 0 & \lambda_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_p^2 \end{bmatrix}, \quad (2)$$

em que δ e λ representam o desvio padrão de ω e ν , respectivamente, considerando ruídos não-correlacionados. As matrizes Q e R podem tanto ter uma interpretação física, quanto serem usadas como parâmetros de ajuste do KF.

Assim, o KF baseia-se nas matrizes de ponderação Q , R e de P , sendo esta última a matriz de covariância dos estados estimados do sistema, e possui duas etapas principais: a estimativa, que utiliza o modelo discreto e a matriz de covariância $P(k|k-1)$ para propagar os ruídos dos estados, e a atualização. Na primeira iteração, a matriz de covariância P é definida como $P(0|0)$, representando a covariância esperada inicial para o instante 0, dado um estado inicial $\bar{x}$ [17]. O passo da estimação é descrito por

$$\hat{x}(k|k-1) = A\hat{x}(k-1|k-1) + Bu(k-1), \quad (3)$$

$$P(k|k-1) = A P(k-1|k-1) A^T + GQG^T, \quad (4)$$

onde $\hat{x}(k|k-1)$ denota o estado estimado $\hat{x}$ no instante k com informações até $k-1$.

Para a atualização, calcula-se o ganho do filtro L e, então, o estado $\hat{x}(k|k)$ e a matriz de covariância $P(k|k)$ são atualizados a partir do ganho encontrado, conforme as seguintes equações:

$$L = P(k|k-1) C^T (C P(k|k-1) C^T + R)^{-1}, \quad (5)$$

$$\hat{x}(k|k) = \hat{x}(k|k-1) + L(y(k) - C\hat{x}(k|k-1)), \quad (6)$$

$$P(k|k) = (I - LC) P(k|k-1), \quad (7)$$

onde I é uma matriz identidade com dimensões adequadas para o cálculo. É interessante notar que, após a atualização, $P(k|k)$ é "menor" que $P(k|k-1)$, indicando a redução da incerteza de $\hat{x}(k|k)$ [17].

Apesar de o algoritmo KF ser variante no tempo, para o caso linear, é possível demonstrar que se k for suficientemente grande, o ganho de atualização L converge para um valor fixo ótimo. Dessa forma, ao calcular um ganho L ótimo ao invés de recalculá-lo a cada instante de tempo, há uma melhora significativa no esforço computacional [17], [19].

O KF possui variações para casos não-lineares como o UKF e EKF. A mais simples em termos de implementação é o EKF que será tratado a seguir, como ponto de estudo de estimadores não-lineares.

B. Filtro de Kalman Estendido - EKF

Apesar de o KF ser apresentar bons resultados, ao implementá-lo em casos não-lineares, ele pode gerar soluções distantes do ponto ótimo esperado [20]. Com isso, surgiram adaptações para aplicação em sistemas não-lineares como o EKF. De forma geral, o EKF realiza a linearização analítica do sistema, utilizando uma aproximação de Taylor de primeira ordem, a cada iteração do processo. A implementação é similar ao KF com algumas modificações que facilitam a propagação da matriz de covariância P através do modelo. Para isso, o EKF utiliza o sistema linearizado para o cálculo de P e o sistema não-linear para a estimação dos estados [17], [21].

Para a estimação dos estados com o EKF, é considerado o sistema não-linear

$$\begin{cases} x(k+1) = f(x(k), u(k), q(k)) + G\omega(k) \\ y(k) = h(x(k)) + \nu(k) \end{cases}, \quad (8)$$

sendo f uma função não-linear multivariável dependente do vetor de estados $x \in \mathbb{R}^n$, vetor de entradas $u \in \mathbb{R}^m$ e da perturbação $q \in \mathbb{R}^{n_q}$. O vetor de saídas é representadas por y , e é obtido pela função não-linear h , que depende dos vetores de estados x .

Assim como no KF, é necessário inicializar o filtro próximo ao ponto de operação do modelo, para então realizar a linearização da dinâmica do processo e obter uma matriz $A(k-1)$,

$$A(k-1) = \left. \frac{df}{dx} \right|_{\hat{x}(k|k-1), u(k-1), q(k|k-1)}. \quad (9)$$

Após isso, são realizados a estimação de $\hat{x}(k|k-1)$ e da matriz de covariância

$$\hat{x}(k|k-1) = f(\hat{x}(k-1|k-1), u(k-1)), \quad (10)$$

$$P(k|k-1) = A(k-1)P(k-1)A^T(k-1) + GQG^T. \quad (11)$$

Para o passo de atualização, é necessário calcular a linearização da função h , obtendo a matriz abaixo:

$$C(k) = \left. \frac{dh}{dx} \right|_{\hat{x}(k|k-1)}. \quad (12)$$

Com isso, inicia-se o passo de atualização a partir do cálculo do ganho do filtro L

$$L = P(k|k-1) C^T(k) (C(k) P(k|k-1) C^T(k) + R)^{-1}. \quad (13)$$

Assim, é possível realizar a etapa de atualização dos estados e da matriz de covariância a partir de

$$\hat{x}(k|k) = \hat{x}(k|k-1) + L(y(k) - h(\hat{x}(k|k-1))), \quad (14)$$

$$P(k|k) = (I - LC(k)) P(k|k-1). \quad (15)$$

É importante notar que o vetor de estados e a saída são estimados através do modelo não-linear, enquanto o ganho e a matriz de covariância são calculados através do modelo linearizado.

A aproximação por séries de Taylor de primeira ordem pode não representar o sistema precisamente, interferindo na precisão das estimações, limitando o sistema às funções diferenciáveis e aumentando a dificuldade da implementação. Em contrapartida, o EKF geralmente apresenta resultados melhores em sistemas não-lineares quando comparado ao KF, obtendo erros menores de estimação [21], [22]. Ainda assim, há outras variações do KF que podem melhorar o desempenho, como em [23] em que é apresentado a aplicação do UKF, o qual não requer funções diferenciáveis e apresenta melhor aproximação da matriz covariâncias.

C. Observadores Estendidos

Na prática, o modelo utilizado para a estimação dos estados sempre tem alguma aproximação ou, então, sofre o efeito de perturbações externas. Quando isso acontece, os observadores apresentados anteriormente podem não ser capazes de conseguir uma estimação com erro nulo pois não consideram nenhum modelo da perturbação. Para contornar este problema, podem ser utilizados os observadores estendidos que podem assumir estruturas variadas como modos deslizantes, observador proporcional integral, observador de alto ganho, e estimam, de forma robusta, estados não mensuráveis e perturbações de maneira assintótica [24], [25].

De maneira geral, o observador estendido linear é descrito a partir do sistema

$$\begin{cases} x(k+1) = Ax(k) + Bu(k) \\ y(k) = Cx(k) \end{cases}, \quad (16)$$

em que as matrizes e vetores são definidos conforme (1). Assim, considerando uma perturbação do tipo constante definida como

$$q(k+1) - q(k) = 0, \quad (17)$$

e definindo que a perturbação age de maneira aditiva ao vetor de entradas u , em que há uma perturbação para cada entrada, pode-se reescrever o sistema como

$$\begin{cases} x(k+1) = Ax(k) + B(u(k) + q(k)) \\ y(k) = Cx(k) \end{cases}, \quad (18)$$

sendo que o sistema pode ser rearranjado considerando a perturbação como um estado

$$\begin{cases} \bar{x}(k+1) = \bar{A}\bar{x}(k) + \bar{B}u(k) \\ y(k) = \bar{C}\bar{x}(k) \end{cases}, \quad (19)$$

onde as matrizes do sistema aumentado são descritas como

$$\bar{x} = \begin{bmatrix} x(k) \\ q(k) \end{bmatrix}, \quad \bar{A} = \begin{bmatrix} A & B \\ 0 & I \end{bmatrix}, \quad \bar{B} = \begin{bmatrix} B \\ 0 \end{bmatrix} e \quad \bar{C} = [C \quad 0] \quad (20)$$

Utilizando essa estrutura, [24] apresenta uma comparação entre os observadores de alto ganho, modos deslizantes e observador de estados estendido não-linear. A simulação utilizada no artigo é de um sistema de controle de movimento industrial linearizado em que todos os observadores são implementados digitalmente, no qual a precisão e velocidade de resposta são os critérios qualitativos avaliados. Nas simulações em malha fechada, utilizando um controlador clássico do tipo Proporcional-Derivativo (PD), a estrutura não-linear foi o que obteve melhores resultados na estimação de perturbações e atenuação de ruídos.

Com isso, o uso de observadores estendidos é justificado pela necessidade de ter as informações com erro nulo de todo o vetor de estados, mesmo que sejam não mensuráveis, para realizar o controle. Ademais, obter dados da perturbação também contribui na melhora do controle. Dessa forma, estados e perturbações podem ser estimados simultaneamente, obtendo um controle mais preciso do sistema a ser tratado [26].

III. PREDITOR DE KALMAN

Ao utilizar o KF como observador na estrutura O&P, tem-se o KP o qual implementa, implicitamente, um FSP, como demonstrado em [7]. Isso confere as mesmas vantagens do FSP ao KP, permitindo a aplicação em sistemas instáveis, melhoria de robustez ou resposta à perturbação do sistema. Para isso, o sistema com atraso considerado para realização da predição utilizando o KP provém do modelo nominal do processo acrescido do estado da perturbação, gerando o vetor de estados aumentado definido por $x_a^T(k) = [x(k)^T \quad q(k)^T]^T$

$$\begin{cases} x_a(k+1) = \bar{A}x_a(k) + \bar{B}u(k-d) + G\omega(k) \\ y(k) = \bar{C}x_a + \nu \end{cases}, \quad (21)$$

em que as matrizes $\bar{A}$, $\bar{B}$ e $\bar{C}$ são descritas conforme (20). A matriz G indica como os ruídos afetam os estados. Assim, como apresentado em [7], consideraremos apenas ruídos nas perturbações estimadas, assim:

$$G = \begin{bmatrix} 0_{n \times m} \\ I_{m \times m} \end{bmatrix}. \quad (22)$$

A ideia base do algoritmo O&P, tomando KF como observador, é [7]:

- 1) Estimar os estados do processo em $\hat{x}(k|k)$, utilizando KF como observador;
- 2) Integrar o modelo do sistema, para obter a predição do sistema após o atraso $\hat{x}(k+d|k)$;
- 3) Usar o sinal $\hat{x}(k+d|k)$, ou $\hat{y}(k+d|k)$, para o controle;
- 4) Repetir a cada período de amostragem.

Se o sistema dado por (21) for detectável, o KF sempre encontrará um observador marginalmente estável [19]. Ademais, é possível implementar o KP em sistemas integradores e/ou instáveis, além de facilitar a análise no domínio da frequência. Outro ponto importante que deve ser destacado é que, caso as entradas tenham atrasos iguais, as equações do KP para casos MIMO são idênticas aos casos SISO [27].

Com base no exposto, é possível utilizar observadores não-lineares como a estrutura do filtro de Kalman apresentada na Seção II-B e, com isso, é possível estudar preditores não-lineares, bem como avaliar questões sobre sua sintonia e influência na rejeição de perturbação e robustez do sistema.

IV. RESULTADOS E DISCUSSÕES

Os resultados referem-se à predição utilizando o KP de maneira adaptada ao caso não-linear, tomando o EKF como estimador e simulando o seu comportamento em um sistema de reator químico comumente tratado em pesquisas desse tema. Foram realizados testes em malha fechada, utilizando um controlador do tipo LQR (do inglês, *Linear Quadratic Regulator*) com dinâmica integradora do erro de seguimento para garantir erro nulo para referência do tipo degrau, além de estudos quanto à sintonia do estimador, alterando as matrizes Q e R , buscando entender e traçar similaridade na sintonia em relação ao caso linear do KP.

A. Caso de Estudo

Existem diversos tipos de reatores para diferentes reações químicas. Um deles é conhecido como reator químico continuamente agitado (CSTR, do inglês *Continuous Stirred Tank Reactor*), utilizado para reações líquidas, apresentado na Fig. 2. Esses sistemas apresentam dinâmicas não-lineares




Figura 2. Sistema CSTR. Fonte: [1] (adaptado).

ao considerar reações paralelas e consecutivas [28]. No caso estudado, tem-se a produção de B através de A pelo processo exotérmico. O balanço de massa e energia apresenta

as equações não-lineares que descrevem o sistema não-isotérmico, escritas por [29]

$$\frac{dh(t)}{dt} = \frac{q_i(t) - q_o(t - \tau)}{A_c} \quad (23)$$

$$\frac{dC_a(t)}{dt} = q_i(t) \frac{C_{af}(t - \tau) - C_a(t)}{V} - R(t)C_a(t) \quad (24)$$

$$\frac{dT(t)}{dt} = q_i(t) \frac{T_i(t) - T(t)}{V} - \frac{\Delta H}{\rho c_p} R(t)C_a(t) - \frac{Q_h(t - \tau)}{\rho c_p V} \quad (25)$$

no qual τ é o atraso do sistema e a velocidade da reação $R(t)$ é descrita por

$$R(t) = k_0 e^{-\frac{E}{RT(t)}}, \quad (26)$$

sendo que os parâmetros utilizados são descritos na Tabela I.

TABELA I
PARÂMETROS PARA CSTR ISOTÉRMICO [29].

Descrição	Parâmetro	Valores	Unidade
Nível dentro do reator	h	1	m
Concentração medida do produto A	C_a	1	kmol/m ³
Concentração do produto A na alimentação do tanque	C_{af}	5	kmol/m ³
Temperatura dentro do reator	T	400	K
Vazão de saída	q_0	0,005	m ³ /s ⁻¹
Concentração de A na alimentação	$\frac{Q_h}{\rho c_p}$	0,75	Km ³ /s ⁻¹
Taxa de remoção de calor	q_i	0,005	m ³ /s ⁻¹
Vazão de entrada	T_i	350	K
Temperatura de entrada do fluido	E/R	1000	K
Área do reator	A_c	0,05	m ²
Volume do reator	V	0,05	m ³
Calor da reação	Δh	-50e6	cal/kmol
Densidades dos líquidos	ρ	1e6	g/m ³
Calor específico	c_p	1	cal/gK
Constante da taxa de reação	k_0	4,87	s ⁻¹
Período de amostragem	T_s	3	s

Deseja-se controlar a concentração de saída do produto A (C_a), a altura do tanque (h) e também a temperatura interna do tanque (T). Para isso, as variáveis manipuladas são a vazão de saída (q_0), a concentração do produto A no fluido de alimentação (C_{af}) e a taxa de calor normalizada ($\frac{Q_h}{\rho c_p}$), tendo ainda como perturbações constantes a vazão de entrada (q_i) e a temperatura externa (T_i).

A título de realizar a validação do algoritmo desenvolvido, foi considerado atraso no sistema:

$$d_{ts} = d_r + d_a, \quad (27)$$

no qual o atraso total do sistema (d_{ts}) é caracterizado pelo atraso real (d_r), em função da distância em que a concentração C_a é medida do reator e o atraso da análise (d_a) que representa o tempo gasto pelo analisador para fornecer o dado da concentração medida, gerando um atraso nominal de 5 amostras (ou 15 s).

B. Estimação e Predição

A estimativa utiliza o algoritmo EKF desenvolvido com base em [17] e [21], em que o vetor estados e a perturbação são estimados com base na entrada atrasada conforme (28). Além disso, considera-se que a perturbação tem seu modelo conhecido. A estimativa de perturbações com modelo não conhecido é tema de estudo em trabalhos futuros.

O modelo utilizado para a estimativa é dado por

$$\begin{cases} x(k+1) = x(k) + T_s(f(x(k), u(k-d), q(k))) \\ y(k) = h(x(k)) \end{cases}, \quad (28)$$

sendo $f(\cdot)$ a função multivariável não-linear que descreve o modelo e $h(\cdot)$ a função multivariável não-linear das saídas do modelo, sendo discretizadas utilizando o método de Euler. Além disso, considera-se o modelo da perturbação como constante $q(k+1) = q(k)$ e $x^T = [h \ C_a \ T]^T$. Ao acrescentar as perturbações no vetor de estados, sendo $\xi^T = [q_i \ T_i]^T$, de forma a obter a estimativa tanto dos estados como das perturbações do sistema, o sistema pode ser reescrito como

$$x_a(k+1) = \begin{bmatrix} x(k) \\ \xi(k) \end{bmatrix}, \quad \tilde{f} = \begin{bmatrix} f(x_a(k), \xi(k), u(k-d)) \\ \xi(k) \end{bmatrix}. \quad (29)$$

e o sistema aumentado é reescrito conforme

$$\begin{cases} x_a(k+1) = \tilde{f}(x_a(k), u(k-d)) \\ y(k) = h(x_a(k)) \end{cases} \quad (30)$$

Dessa forma, a partir de (30) e utilizando os estados estimados, é realizado a integração do modelo obtendo a predição dos estados e perturbações d -passos a frente, fazendo com que o controlador não sinta o efeito do atraso, permitindo que seja projetado a partir dessa premissa.

C. Controle

O controlador, seguindo o mesmo princípio do caso linear, é projetado desconsiderando o atraso do sistema. Assim, para o projeto do controlador, é utilizada a estratégia de controle LQR para o modelo (16) linearizado no ponto de operação definido na Tabela I.

Para o seguimento de sinais de referência constantes, é preciso incluir uma dinâmica integradora na lei de controle, de modo a obter erro nulo. Com isso, a lei de controle passa a ser $u(k) = -K_1 x(k) - K_2 \zeta(k)$ construindo o sistema aumentado a partir do estado integrador

$$\zeta(k+1) = \sum_{i=0}^{\infty} e(i) \quad (31)$$

que pode ser representado de forma recursiva como

$$\zeta(k+1) = \zeta(k) + e(k), \quad (32)$$

em que $e(k)$ é o sinal erro definido como a diferença entre a referência e o sinal de saída do sistema $e(k) = r(k) - y(k)$.

Com isso, é possível reescrever o sistema de maneira aumentada como

$$\begin{cases} x_a(k+1) = A_a x_a(k) + B_a u(k) + E_a r(k) \\ u(k) = -K_a x_a(k) \end{cases}, \quad (33)$$

em que

$$x_a(k+1) = \begin{bmatrix} x(k+1) \\ \zeta(k+1) \end{bmatrix}, \quad A_a = \begin{bmatrix} A & 0 \\ -C & I \end{bmatrix}, \quad B_a = \begin{bmatrix} B \\ 0 \end{bmatrix}, \quad (34)$$

$$E_a = \begin{bmatrix} 0 \\ I \end{bmatrix} \quad e \quad K_a = [K_1 \ K_2].$$

Com isso, resta definir as matrizes de ponderação do algoritmo LQR, Q_{LQR} , que define a relevância dos estados e R_{LQR} , que está relacionado com o esforço de controle:

$$Q_{LQR} = \text{diag}(1, 1, 1/400^2, 1, 1, 1/400^2), \quad (35)$$

$$R_{LQR} = 30 \cdot \text{diag}(1/0,005^2, 1/5^2, 1/0,75^2), \quad (36)$$

em que $diag(v)$ representa uma matriz diagonal com os elementos de v na diagonal principal. A sintonia do LQR é realizada utilizando a regra de Bryson, na qual as matrizes Q e R são definidas com base no maior valor da resposta ou entrada desejado. Com isso, conforme descrito na Seção IV-D, os testes são iniciados em malha aberta para validar o algoritmo de predição e, só então, são realizados os testes em malha fechada.

D. Simulações

Para a validação do estimador, foi proposto um primeiro cenário de simulação em que não há erros de modelagem, preditor e sistema real possuem o mesmo atraso, e que o sistema estimado está no mesmo ponto inicial do sistema real. Nesse sentido, é importante ressaltar que a ponderação no filtro é $Q = R = I$, com I sendo uma matriz identidade de dimensões adequadas, denominada de Sintonia 1. Como um dos objetivos deste trabalho é apresentar estudos quanto à sintonia do preditor utilizando EKF como estimador sob a técnica O&P, não serão realizadas comparações com outras variações do filtro de Kalman, sendo estes objetivos de trabalhos futuros. Baseado nisso, foram implementados degraus de 2% nos sinais de entrada (C_{af}) e de perturbação (q_i e T_i) em torno do ponto de operação, observando a saída do sistema em malha aberta.

Com isso, na Fig. 3 são apresentadas as saídas do estimador em malha aberta para um degrau positivo em q_i e em T_i a 200 e a 400 segundos, respectivamente. Em 100 s, foi aplicado um degrau positivo em C_{af} .




Figura 3. Comparação entre estados preditos e a saída real do sistema em malha aberta utilizando a Sintonia 1. Fonte: Autoria Própria.

A partir da Fig. 3, é possível observar que o sinal de predição converge para o sinal real dos estados. No mesmo âmbito, tem-se a Fig. 4, em que é apresentada a predição das perturbações com relação às perturbações reais, para o mesmo cenário, no qual é possível observar a dinâmica do preditor e a convergência para o sinal real, validando o algoritmo de predição. A Tabela II apresenta os valores de erro para cada saída, utilizando como métrica o RMSE (do inglês *Root Mean Squared Error*), definido para um sinal




Figura 4. Comparação entre sinal de perturbação real e predita do sistema em malha aberta para Sintonia 1. Fonte: Autoria Própria.

genérico x como

$$\varepsilon_x = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2} \quad (37)$$

em que N é o número de amostras, x é a saída real e $\hat{x}$ a saída predita, mantendo a unidade da variável analisada.

TABELA II
RMSE SISTEMA EM MALHA ABERTA

Cenário	$\varepsilon_h(m)$	$\varepsilon_{C_a}(kmol/m^3)$	$\varepsilon_T(K)$
Sintonia 1	0,0343	0,0045	3,2428

Com o algoritmo de predição validado em malha aberta, é realizada a validação do algoritmo de controle desenvolvido, incluindo o controlador para o mesmo cenário anterior, e observando agora a saída do sistema em malha fechada.

Na Fig. 5 são apresentados os sinais de saída real e saída predita do sistema em malha fechada. Em 100 s uma mudança de referência de C_a , em 200 s, há uma alteração no sinal de q_i e em 400 s um degrau na perturbação T_i . Assim, é possível ver o seguimento da referência após o atraso e com erro nulo, além da rejeição das perturbações. Através dos resultados apresentados, foi possível validar o uso da estrutura O&P utilizando o EKF como estimador, com base na predição e erro de seguimento de referência convergindo para zero.

Em seguida, foi realizado um estudo voltado à sintonia do filtro, através das matrizes Q e R . A nova sintonia foi baseada nas diretrizes apresentadas em [27], de forma que à medida que se aumentam as variâncias da matriz Q , a resposta do preditor torna-se mais agressiva. Para a matriz R , à medida que aumentam-se as variâncias, o sistema tende a aumentar a robustez. Com esse propósito, a sintonia é realizada de maneira independente do controlador, o qual é fixo para todas as simulações.

Com isso, tem-se a Fig. 6 com a comparação da saída com a predição do sistema. Neste caso, foram utilizadas as




Figura 5. Comparação entre sinal de saída real e predita do sistema em malha fechada utilizando a Sintonia 1. Fonte: Autoria Própria.

ponderações

$$Q = \text{diag}(\delta_1^2, \delta_2^2) \quad (38)$$

$$R = \text{diag}(\lambda_1^2, \lambda_2^2, \lambda_3^2) \quad (39)$$

em que $\delta_1 = 0,0015$, $\delta_2 = 5$, $\lambda_1 = 0,5$, $\lambda_2 = 0,5$ e $\lambda_3 = 5$ são os respectivos desvios padrões estabelecidos com base na faixa de valores de cada variável, sendo esta denominada como Sintonia 2.

Através da comparação entre as Figuras 5 e 6 em que ambas apresentam a simulação do sistema para o caso nominal, é possível observar a maior capacidade de rejeição de perturbação ao aplicar a Sintonia 2, conforme a análise quantitativa, apresentada na Tabela III, em que o erro de predição ao utilizar a Sintonia 2 é menor para todas as saídas do sistema, validando a metodologia para sintonia apresentada em [27].

TABELA III
RMSE SISTEMA EM MALHA FECHADA

Cenário	$\varepsilon_h(m)$	$\varepsilon_{C_a}(kmol/m^3)$	$\varepsilon_T(K)$
Sintonia 1	0,0156	0,0060	3,3145
Sintonia 2	0,0085	0,0045	0,6916

Entretanto, é bastante comum encontrar erros de modelagem, haja vista as simplificações feitas durante esse processo. Para esse trabalho, serão considerados apenas erros de modelagem com relação ao atraso do sistema. Com isso, utilizando o mesmo controlador e preditor anterior e adicionando um erro de modelagem no qual o atraso modelado passa a ser $d_{tm} = 30 s$, o sistema torna-se instável, conforme apresentado na Fig. 7. Visando atingir a estabilidade do sistema em malha fechada, foi proposto a Sintonia 3, em que as matrizes Q e R são descritas por

$$Q = \text{diag}(0,01\delta_1^2, 0,6\delta_2^2), \quad (40)$$

$$R = \text{diag}(\lambda_1^2, 100\lambda_2^2, 20\lambda_3^2), \quad (41)$$

seguindo as diretrizes de sintonia apresentadas anteriormente, as matrizes Q e R são projetadas de maneira a melhorar a robustez do sistema. Os resultados são apresentados na Fig 8. Com a Sintonia 3, que ajusta apenas o preditor, o




Figura 6. Comparação da saída real e predita do sistema para o caso sem erros de modelagem utilizando a Sintonia 2. Fonte: Autoria Própria.




Figura 7. Comparação da saída real e predita do sistema para o caso com erros de modelagem utilizando a Sintonia 2. Fonte: Autoria Própria.




Figura 8. Estabilização do sistema para o mesmo cenário com erro de modelagem utilizando a Sintonia 3. Fonte: Autoria Própria.

sistema permanece estável para o mesmo cenário anterior. Ou seja, o sistema de malha fechada se tornou mais robusto. Estes resultados evidenciam que o efeito que o preditor tem em termos de robustez e rejeição de perturbações para o caso linear ainda é válido para o caso não-linear, apesar de que as provas matemáticas ainda não foram completamente descritas.

Além disso, é possível observar também que as predições da saída geradas pelo preditor (Fig. 8), são menos afetadas pelas perturbações não medidas do sistema, o que faz com que o controlador primário reaja de forma mais suave, o que, consequentemente, torna a malha fechada mais robusta. Isto, claro, afeta a rejeição de perturbações, que fica mais lenta.

V. CONCLUSÕES

Neste trabalho, foi proposto um preditor não-linear baseado no EKF e na estrutura de O&P que pode ser aplicado a sistemas multivariáveis não-lineares com atraso e com qualquer tipo de dinâmica (estável ou não). Foram investigadas as características que esta estrutura confere à malha fechada considerando rejeição de perturbações e robustez.

Através do caso de estudo, foi mostrado que a sintonia do preditor é relativamente simples e não envolve a definição de polos e zeros, como outras da literatura. Ajustando adequadamente o preditor, é possível melhorar a rejeição de perturbações e/ou a robustez do sistema. Entretanto, a limitação atual está em utilizar um atraso comum para todas as entradas e na forma de tratar as perturbações. Desta forma, serão realizados estudos sobre qual a melhor maneira de incorporar o sinal de perturbação, para que o preditor seja aplicável a sistemas não-lineares com perturbações não modelada. Além disso, é possível explorar o UKF como estimador para obter predições ainda mais precisas, quando comparado ao EKF, e também a não limitar sua implementação à sistemas diferenciáveis, uma vez que o UKF realiza todas as estimações com o modelo não-linear do sistema, bem como as provas matemáticas dos resultados obtidos através de simulação.

REFERÊNCIAS

- [1] NORMEY-RICO, J. E.; CAMACHO, E. F. "Control of Dead-Time Processes". [S.l.]: Springer Science & Business Media, 2007.
- [2] PALMOR, Z. J. "Time-delay compensation - Smith predictor and its modifications". In: LEVINE, William S. (Ed.). *The Control Handbook*. [S.l.]: CRC e IEEE Press, 1996. cap. 10.8, p. 224-237.
- [3] SANTOS, T. L. M., RAFFO, G. V., LIMON, D., NORMEY-RICO, J. E. "On the prediction error of dead-time compensation control for constrained nonlinear systems", 2014 European Control Conference (ECC), Strasbourg, France, 2014, pp. 784-789, doi: 10.1109/ECC.2014.6862317.
- [4] NORMEY-RICO, J. E., CAMACHO, E. F. "Unified approach for robust dead-time compensator design", *Journal of Process Control*, Volume 19, Issue 1, 2009, Pages 38-47, ISSN 0959-1524, <https://doi.org/10.1016/j.jprocont.2008.02.003>.
- [5] LIU, T., GARCÍA, P., CHEN, Y., REN, X., ALBERTOS, Pe., SANZ, R. "New Predictor and 2DOF Control Scheme for Industrial Processes With Long Time Delay". *IEEE Transactions on Industrial Electronics*, Institute of Electrical e Electronics Engineers Inc., v. 65, n. 5, p. 4247-4256, 2018. ISSN 02780046.
- [6] MIRKIN, L., RASKIN, N. "Every stabilizing dead-time controller has an observer-predictor-based structure". *Automatica*, v. 39, n. 10, p. 1747-1754, 2003. ISSN 0005-1098.
- [7] LIMA, D. M., LIMA, B. M., NORMEY-RICO, J. E. "A predictor for dead-time systems based on the Kalman Filter for improved disturbance rejection and robustness". *Journal of Process Control*, v. 105, p. 108-116, 2021. ISSN 0959-1524.
- [8] HASELTINE, E. L., RAWLINGS, J. B. "Critical Evaluation of Extended Kalman Filtering and Moving-Horizon Estimation", *Ind. Eng. Chem. Res.*, vol. 44, no. 8, pp. 2451-2460, Apr. 2005, doi: 10.1021/ie034308l.
- [9] BEKIARIS-LIBERIS, N., KRSTIC, M. "Robustness of nonlinear predictor feedback laws to time- and state-dependent delay perturbations", *Automatica*, Volume 49, Issue 6, 2013, Pages 1576-1590, ISSN 0005-1098.
- [10] CUENCA, Á., ZHAN, W., SALT, J., ALCAINA, J., TANG, C., TOMIZUKA, M. "A Remote Control Strategy for an Autonomous Vehicle with Slow Sensor Using Kalman Filtering and Dual-Rate Control". *Sensors* 2019, 19, 2983. <https://doi.org/10.3390/s19132983>
- [11] LIMA, D. M., SANTOS, T. L. M., NORMEY-RICO, J. E., "Robust nonlinear predictor for dead-time systems with input nonlinearities", *Journal of Process Control*, Volume 27, 2015, Pages 1-14, ISSN 0959-1524, <https://doi.org/10.1016/j.jprocont.2015.01.005>.
- [12] LIMA, D. M., SANTOS, T. L. M., NORMEY-RICO, J. E. "A robust predictor for nonlinear systems with dead time", 2015 54th IEEE Conference on Decision and Control (CDC), Osaka, Japan, 2015, pp. 7548-7553, doi: 10.1109/CDC.2015.7403411.
- [13] KAMESH, R., RANI, K. Y. "Iterative EKF as a controller in novel MPC formulation: First principles model based IEKF-MPC for SISO systems", *Computers & Chemical Engineering*, Volume 163, 2022, 107833, ISSN 0098-1354.
- [14] JANA, A. K., Ganguly, S., Samanta, A. N. "Nonlinear control of a multicomponent distillation process coupled with a binary distillation model as an EKF predictor", *ISA Transactions*, Volume 45, Issue 4, 2006, Pages 575-588, ISSN 0019-0578, doi: [https://doi.org/10.1016/S0019-0578\(07\)60233-X](https://doi.org/10.1016/S0019-0578(07)60233-X).
- [15] ARCHAR, A., NATARAJAN, A., ROHITH, R., KUMAR, B. A. "Predicting public transit arrival: A nonlinear approach" *Transportation Research Part C: Emerging Technologies*, Volume 144, 2022, 103875, ISSN 0968-090X, doi.org/10.1016/j.trc.2022.103875.
- [16] RASHEDI, M., LIU, J., HUANG, B. (2016), "Communication delays and data losses in distributed adaptive high-gain EKF". *AIChE J.*, 62: 4321-4333. doi.org/10.1002/aic.15351
- [17] LIMA, B. M. "Economic model predictive control and optimal estimation for nonlinear systems". 2018. Universidade Federal de Santa Catarina.
- [18] Zhang, Q., Zhang, L. "Stability Analysis of the Kalman Predictor", *International Journal of Control*, 2019, 10.1080/00207179.2019.1638971.
- [19] SIMON, D. "Optimal State Estimation: Kalman, H Infinity, and Nonlinear Approaches". 1st edition. [S.l.]: Wiley-Interscience, 2006. ISBN 9780471708582.
- [20] KONATOWSKI, S., PIENI, A. T. "A Comparison Of Estimation Accuracy By The Use Of KF, EKF & UKF Filters" (2007).
- [21] PLETT, G. L. "ECE5550: Applied Kalman Filtering - Nonlinear Kalman Filters". <http://mocha-java.uccs.edu/ECE5550/>, 2018.
- [22] RAMPELLI, M., JENA, D. "Advantage of extended kalman filter over discrete kalman filter in dynamic state estimation of power system network". *International Journal of Control Theory and Applications*, 2016.
- [23] JULIER, S. J., JEFFREY K. U. "New extension of the Kalman filter to nonlinear systems". *Defense, Security, and Sensing* (1997).
- [24] WANG, W., GAO, Z. "A comparison study of advanced state observer design techniques". In: *PROCEEDINGS of the 2003 American Control Conference*, 2003. [S.l.: s.n.], 2003. v. 6, 4754-4759 vol.6.
- [25] GODBOLE, A. A.; AMBREEN, A. "Disturbance observer augmented sliding mode control for mismatched uncertain system". In: 2016 2nd International Conference on Communication Control and Intelligent Systems (CCIS). [S.l.: s.n.], 2016. P. 154-158.
- [26] SAWAI, S., KURODE, S. "Simultaneous State and Disturbance Estimation for Robust tracking Control in Discrete Motion System". *IFAC-PapersOnLine*, v. 53, n. 1, p. 159-163, 2020. 6th Conference on Advances in Control and Optimization of Dynamical Systems ACODS 2020. ISSN 2405-8963.
- [27] LIMA, D. M., LIMA, B. M., NORMEY-RICO, J. E. "A predictor for square multivariable dead-time systems with multiple delays based on the Kalman filter". *Journal of Process Control*, Volume 124, 2023, Pages 105-117, ISSN 0959-1524, doi.org/10.1016/j.jprocont.2023.02.016.
- [28] LIMA, D. M. "Predictor-based Robust Control of Dead-time Processes". 2015. Tese (Doutorado) – Universidade Federal de Santa Catarina - UFSC.
- [29] GUPTA, Y.P. "Control of Integrating Processes Using Dynamic Matrix Control", *Chemical Engineering Research and Design*, Volume 76, Issue 4, 1998, Pages 465-470, ISSN 0263-8762, doi.org/10.1205/026387698525081.